

SMT 锡膏印刷质量 Agent — 交付讲解手册

面向源代码交付场景：向客户完整讲清楚这套系统是什么、数据怎么流、每个结论怎么来、代码在哪、怎么改、边界在哪。按本手册顺序讲即可；每节都标注了对应源码位置。

交付时同读：README.md（安装运行）、docs/ 下各设计文档（每个大功能的决策记录）。本手册是总览与导读，设计文档是每个决定"为什么这样做"的存档。

一、这套系统是什么

一句话：盯着 SPI（锡膏检测）数据流的质量分析 Agent——异常发生时自动下钻找根因、给处置建议；异常发生前用漂移监控提前预警；全部结论可审计、可追问。

能力清单（对应前端六个页签）：

能力	页签	干什么
实时异常	实时异常	逐行判定 NG 类型/风险等级/异常模式，生成质量案例
事前预警	事前预警	每个焊盘的 EWMA 漂移监控 + 健康矩阵，NG 之前报警
质量案例	质量案例	中高风险异常沉淀为案例，跟踪复测与关闭
统计看板	统计看板	汇总指标 + TOP

		排名（窗口口径为主、全表累计为副）
事件与根因	事件与根因分析	NG 板聚类成事件、前兆回溯、参数排除、工艺维度体检
三板连发下钻	（从实时异常/事件进入）	同一焊盘连续 ≥ 3 板 NG 的完整根因分析工作台 + 对话
知识库	机理手册	13 个失效机理手册 + 维护视图（词表/决策流程/处置阶梯）

工程特征（讲给客户的技术负责人）：

- **零第三方依赖**：纯 Python 标准库 + 前端原生 JS，部署 = 一个 Python 进程；数据库访问走 `psql` 子进程，LLM 调用走 `urllib`。
- 约 7300 行 Python（15 个模块）+ 3 个前端文件，190 个单元测试。
- 所有分析每轮**从同一份数据快照全量重算**（幂等），没有增量状态机——数据速率（约 45 板/天）远不需要流式计算的复杂度。

二、总体架构与数据流

数据流（自上而下）

1. PostgreSQL 的 `full_excel` 系表（生产实时写入表）；
2. `serve.py` 内的 `Watcher` 线程每 5 秒查一次表指纹（行数 + 最新时间戳），指纹变

化才触发重算；

3. run_pipeline 按滑动窗口取最近 3000 块板，一次读取形成快照；
4. 同一份快照喂给四个分析 stage，分别产出 output/ 下的 abnormal_results / param_analysis / drilldown / early_warning 四个 JSON；
5. HTTP 服务只暴露 /web/*（静态前端）、/output/*（分析结果）与 /api/*（动态接口）；
6. 浏览器每 4 秒轮询 /api/live 的数据版本号，版本变了才重新拉取数据并提示。

要点讲解：

1. **单快照一致性**：四个 stage 消费同一次数据库读取的结果，所以实时异常、事件、下钻、预警之间**永远不会互相矛盾**（不存在"两次查询之间来了新数据"）。
2. **滑动窗口**：每轮只加载最近 N 块板（配置 realtime_window_boards，默认 3000 ≈ 66 天产量；0=全表）。所有分析的回溯需求都远小于窗口（最大 20 板 / 500 行），因此窗口重算与全量重算在重叠范围内**逐字节一致**（已验证）。需要历史全量时 POST /api/refresh 带 {"window_boards": 0} 按需跑。
3. **变更感知**：watcher 的指纹是 count(*) + max(解析后的时间戳)。注意 fdate 是不补零的文本（2024/1/4 9:58），直接 max(fdate) 文本序跨月会错，所以 SQL 侧一律用 pipeline.fdate_ts_expr()（正则守卫的 to_timestamp）。
4. **重启不丢状态**：output/live_state.json 落盘版本号/指纹/窗口；重启后 版本续增，前端无感。
5. **确定性 ID**：三板连发触发 TRG-<hash>、漂移预警 WRN-<hash> 都由 "起始板身份" 哈希派生——窗口滚动、服务重启、重算之后 **ID 不变**，已读/确认状态因此能跨重算延续。

三、数据与口径（先讲清楚，后面全靠它）

数据源：l780db.public.full_excel0625（配置 tables.full_spi，客户产线以实际的 full_excel 系实时写入表为准）。每行 = 一块板上一个焊盘的一次 SPI 测量，约 87 列：板条码/时间/机种/焊盘名 + 三个测量偏差 + 印刷参数三元组（<参数>_plan 计划值 / <参数> 实际值 / diff_<参数> 差值）。

五个必须讲对的口径（历史上都踩过坑）：

1. **Comp_avdp/aadp/ahdp 是无符号偏差幅度**（体积/面积/高度），全表最小值 0。多锡和少锡的 avdp 可能一样大——**缺陷方向只在 Comp_errName 标签里**。因此所有监控都是"幅度爬升=变坏"的单边逻辑，机理签名表达的是"哪些指标劣化"而不是物理升降方向。
 2. **NG 判定**：Comp_errName 非空且大写后 $\neq$ "PASS" (param_correlation.is_ng)。
 3. **首检 vs 复测**：同一板条码在更晚时刻再次出现 = 复测。复测**不算生产板**：不参与连发判定、不进基线，但保留在趋势图和恢复判定里（复测 PASS 是"已恢复"的证据）。
 4. **fdate 是文本**：Python 侧统一 parse_fdate()，SQL 侧统一 fdate_ts_expr()。任何新查询直接比较 fdate 文本都是 bug。
 5. ***_plan 是伪设定值陷阱**：部分"计划值"列逐板都在变（跟随实际值），不能当真正的程序设定值用；参数变更事件检测已对此做了处理。
-

四、四条分析流水线（pipeline.py 编排，故障互相隔离）

任何一个 stage 失败只影响自己的 JSON 文件，其余照常产出；前端对失败的 stage 显示诚实的错误态而不是空白。

4.1 anomaly_cases —— 实时异常与质量案例（rules_engine.py）

首检行逐行过规则引擎：判 NG 类型（多锡/少锡）、风险等级（高/中/低）、异常模式（孤立/同板多点/连续同点……），中高风险沉淀为质量案例。输出 abnormal_results.json / quality_cases.json / dashboard_summary.json（含 scope 窗口口径 + cumulative 全表真累计——真累计来自一条纯聚合 SQL，不拉明细，失败不拖垮 stage） / dashboard_top.json。

4.2 param_analysis —— 事件与根因分析（param_correlation.py + process_dimensions.py）

- **事件聚类**：同机种 NG 板按 30 分钟间隔聚成"事件"；

- **前兆回溯**：事件前 20 块正常板的板均偏差，斜率 $\geq 0.5\%/板$ 且末段连升 ≥ 3 板判"渐变型（有前兆）"，否则"突发型"；
- **参数排除法**：事件时段的参数实际-计划偏差与基线对比，给出"参数无偏离/某参数偏离"的核查结论；
- **复测有效率**：复测 PASS 占比；
- **工艺维度体检（P1）**：清洗周期效应/停机首板效应/印刷方向差异三张体检卡，每轮重算，如实报告四态之一（存在效应/无明显效应/样本不足/数据未采集），判效应门槛 = $\max(1pp, 0.5 \times \text{板均噪声 } \sigma)$ 。当前数据三个维度均无效应——这是**如实结论**，数据变了会自动点亮。

4.3 drilldown —— 三板连发下钻（drilldown.py，系统的核心深度）

触发：同一"机种×焊盘"连续 ≥ 3 块生产板 NG 且中间无 PASS（严格口径，复测不计入）。触发 ID 确定性派生。

围绕触发自动建包（详见第六节的完整案例走读）：

- 焊盘自身序列窗口（前后各 300 条）+ 全量 SPI 上下文窗口（前后各 500 条，**含所有焊盘**——范围判定必须看别的 Pad）；
- 观测层判定：范围（单 Pad 孤立/同元件多 Pad/局部区域/整板同向/疑似 SPI 假异常）、趋势（突变/渐变）、恢复、周期性、参数核查、三指标签名（判界 $\max(3\sigma, 10pp)$ ）、擦网频率参照；
- 决策四步（第六节）产出根因候选（前 3）+ 处置分级 + 复判计划；
- **analysis_contract 是唯一权威结论载荷**（版本 analysis-contract-v4）：前端展示、对话回答、诊断轨迹全部以它为准，不存在第二份结论。

4.4 early_warning —— 事前预警（early_warning.py，P0）

- **监控**：92 个焊盘 + 1 条整板均值序列，各自做三指标 EWMA（ $\lambda=0.2 / L=4.0$ ，回测标定，配置可调）；基线 = 滚动 200 块板的 PASS 值，**报警期间冻结**（漂移不能拉高自己的控制限），预热 30 板；
- **分级**：L1 观察（越限 1 板）→ L2 预警（连续 ≥ 3 板或双指标共振）→ L3 高危（L2 且末段连升 ≥ 3 ，或 avdp 进入历史 NG 观测带）；

- **消费方式**（评审拍板）：只有**活动中的 L3** 弹页面提示（约 1.5 条/天）； L1/L2 沉淀进 Pad 健康矩阵（按漂移裕度 margin 着色）；
- **台阶式新常态**：越限持续 ≥ 100 板不回落的活动告警转入"待确认新常态"桶， 工程师点"接受为新基线"→ ack 按确定性 ID 落盘 `output/warning_acks.json` → 该焊盘从迁移点重启监控（跨重算生效）；
- **margin**：距历史 NG 最低观测水位还有几个 3σ 。**注意这不是真 Cpk**—— SPI 判定阈值未拿到，页面如实标注； 阈值到位后同字段换真 Cpk。

五、知识层——机理手册与规则（`ontology.py` + `knowledge_base.py`）

分层原则（机理手册页底部"维护视图"里有同样的说明）：

层	回答什么	内容	说错了怪谁
观测层	数据里发生了什么	三个判定轴（空间	计算逻辑
		×时间	编辑
		×有效性，11	bug
		个取值）+ 25 种证据	→ 代码
机理	为什么会	13 个失效机理	知识

			错
		(根因	→
		词表唯	改
层	这样	一权	机
		威)	理
			卡
			策
			略
		10 条决	松
		策规则 +	紧
决	怎么	6 级处置	→
策	判怎	阶梯 +	调
层	么办	置信度	阈
		算式	值/
			顺
			序
		工序/部	
	落在	位/物料	
实	哪个	骨架	—
体	物理	(薄,	
层	对象	待	
		MES)	

机理是单源：诊断候选、预警提名、chat 回答、事件归因里出现的每个根因 说法都引用同一份机理定义。每张机理卡四个可执行字段：

- **先验** (confidence_base)：核对证据前的初始把握度（如范围先验 0.7、投影兜底 0.45）——决策第 2 步的起点分数；
- **签名** (signature)：该机理发作时三指标各自的表现（如残锡转印 "体积 ↑ 面积 ↑ 高度平/↑") ——决策第 3 步吻合 ×1.2 / 方向冲突 ×0.7；
- **典型范围** (typical_spatial)：驱动候选投影和空间典型性 ×1.1/×0.9；

- **动作 (action)**：确认后现场干的第一件事，直接进处置建议。

改知识的流程：改 `ontology.py` 里的机理定义 → 跑测试（守护测试锚住 词表/绑定/口径）→ 版本串升级（当前 `spi-printing-v5 / rule-catalog-v6`）。全系统自动跟随，无需逐处同步。

置信度模型（`/api/rules` 的 `confidence_model` 块单源暴露，页面算式卡 自动跟随常量）：

最终把握 = 先验 × 签名(吻合 1.2/冲突 0.7) × 空间典型性(1.1/0.9)

× 擦网对齐(1.15) × 跨机种基线(0.8)，封顶 0.95

分档：≥0.75 高 / ≥0.5 中 / <0.5 低（分档是推导的，不单独维护）

六、决策流程完整走读（拿真实案例讲）

给客户演示时用这个真实案例：**2023/12/6 上午，C1754_2 连续 3 块板多锡**（TRG-d1489186）。

1. **数据到达**：watcher 发现指纹变化 → 拉最近 3000 板快照 → 识别复测行；
2. **触发判定**：C1754_2 在 10:30/10:33/10:36 连续 3 块生产板 Over Volume，中间无 PASS → 生成触发；
3. **观测层算事实**（只描述不解释）：
 - 范围：兄弟 Pad 和整板上下文都干净 → **单 Pad 孤立异常（高）**；
 - 趋势：触发前基线稳定 31.5%、斜率 -0.55%/板 → **突变型**；
 - 恢复：触发后第 1 块板即消失 → **已恢复**，且恢复前有 xbackward/xforward 程序设定变更（记录在案）；

- 签名：三指标何者劣化，按 $\max(3\sigma, 10pp)$ 判界；SPI 真伪：偏差与标签相符。

1. 决策第四步（全程记入诊断轨迹）：

- 这个 NG 是真的吗？是 → 不走假异常口径；
- 可能是哪里出的问题？提名三条嫌疑：残锡转印（范围先验 0.7）、参数漂移（恢复前有设定变更，先验 0.85）、离散制程变化（0.6）；
- 把握有多大？残锡转印签名吻合 $\times 1.2$ 、单 Pad 是其典型范围 $\times 1.1 \rightarrow 0.924$ 高；参数漂移的典型范围是整板/局部而这次是单 Pad $\times 0.9 \rightarrow 0.765$ ；
- 现场先干什么？排序取前 3 → 处置 P2 按首要根因执行现场确认，动作来自机理卡："清洁钢网底面并复测下一块板，核对擦网周期"+ 复判标准。

1. 到人眼前：实时异常行挂 ☒ 徽标、新触发 toast、下钻工作台（趋势图/对比/结论/诊断轨迹折叠区——每条规则命中/未命中、置信算式、落选原因全在）、对话区可追问（第七节）。

强调给客户的两点：**证据冲突不和稀泥**（本例"参数变更时序巧合"与"签名指向残锡"两条证据都列出、按证据强度排序）；**每一步可审计**（诊断轨迹就是决策流程对这一次触发的逐条求值记录）。

七、前端页面导览（web/ 三个文件，原生 JS 无框架）

- 实时异常：逐行异常 + 过滤/搜索；三板连发行带 ☒ 下钻入口；
- 事前预警：漂移告警卡（实测/EWMA/控制限三线图 + 机理提名）、待确认新常态（"接受为新基线"按钮）、92 Pad 健康矩阵（margin 着色排序）；
- 质量案例 / 统计看板：案例跟踪与汇总指标（指标区下方脚注 = 窗口口径标注[数据超窗才显示] + 数据源全表累计）；
- 事件与根因分析：事件总览、下钻决策卡、工艺维度体检三卡、事件列表；
- 机理手册：13 张机理卡按缺陷方向分组（多锡/少锡/双向/兜底），每卡"什么现象 → 怎么确认 → 确认后怎么办"；底部折叠"维护视图"（三轴词表、关系全景图、决策四步流程+置信度算式卡、处置阶梯）；
- 下钻工作台（全屏 overlay）：主趋势图（基线带/触发区/参数事件线/参数曲线

- 叠加双轴)、兄弟 Pad 对比/热力图、结论与证据、诊断轨迹、**对话分析**——已配置 LLM 时由所选大模型基于分析契约+机理目录回答 (每条回答标注来源), 未配置/失败自动回退离线规则问答;
- **顶栏**: 实时徽标 (连接状态)、机理手册、LLM 配置 (六家提供商可选)、数据源配置、手动刷新。

自动更新提示优先级: 新三板连发触发 > 新 L3 漂移预警 > 新异常 > 普通更新。

八、HTTP API 清单 (serve.py)

方法 路径	作用
GET /web/*, /output/*	静态前端与分析结果 (只暴露这两个目录)
GET /api/live	数据版本/更新时间/窗口, 前端 4s 轮询
POST /api/refresh	手动重算; body {"window_boards":0} 强制全表
GET /api/status	各 stage 输出文件新鲜度
GET/POST /api/datasource, POST /api/datasource/test	数据库配置 (密码掩码)
GET/POST /api/llm, POST /api/llm/test	LLM 配置 (密钥掩码; test 实调一次)
POST /api/drilldown/chat	对话: LLM 优先、规则兜底
POST /api/warning/accept-	接受台阶迁移为新基线 (落盘+重

baseline	算)
GET /api/ontology, GET /api/rules	本体快照 / 规则目录 (含 confidence_model)

九、配置项（全部在 config/, 两个 json 均已 gitignore 保护凭据）

datasource.json（模板 datasource.example.json）：

键	含义	默认
host/port/database/ user/password	Postg reSQ L 连 接	本机 socket / l780db
tables.full_spi	全量 SPI 实 时写 入表	full_excel0 623
fields.time/board/ component_pad/ defect	字段 名映 射	fdate/ barcode/ compname / comp_errn ame
refresh_interval_seco nds	watc her 轮询	30 (CLI -- watch- interval 可

	间隔	覆盖)
	滑动	
	窗口	
realtime_window_bor	板	3000
ards	数，	
	0=全	
	表	
	EWM	
	A 参	
early_warning.lambda	数	0.2 / 4.0
/ .L	(回	
	测标	
	定)	

llm.json (模板 `llm.example.json`；也可全在页面配置)： `enabled / provider`
(`openai/anthropic/gemini/deepseek/qwen/hipu`) / `api_key / model / base_url /`
`timeout_seconds`。模型和端点可改 (代理网关/新模型无需改码)。

十、部署与运维

```
python3 serve.py # 跑 pipeline + watcher + 服务 :8502

python3 serve.py --port 8080 --watch-interval 10

python3 serve.py --no-watch # 关自动更新
```

```
python3 serve.py --no-refresh-on-start # 启动不重算(数据没变时秒起)
```

```
python3 serve.py --database otherdb # 覆盖库名
```

- 依赖：Python 3.10+、psql 客户端可连库。无 pip install。
- 重启行为：live_state.json 保证版本续增、指纹延续、不空刷。
- 需要持久化备份的文件：config/*.json（凭据/参数）、output/warning_acks.json（已接受的新基线）。其余 output/*.json 可重算。
- 网络面：建议防火墙只放行服务端口；服务本身**无认证**，定位是工厂内网工具。
- 生产建议（交付时明说）：screen/systemd 托管 + 存活监控；数据量到百万行级 时给生产表加真 timestamp 列或自增 id 并建索引（见 docs/realtime_production_design.md § 6）。

十一、代码结构导览

```
serve.py HTTP 服务/watcher/状态持久化/所有 API (约 400 行)
```

```
smt_quality_agent/
```

```
pipeline.py 四 stage 编排、滑窗查询、指纹、累计聚合、acks 读取
```

```
datasource.py 数据源配置读写/psql 封装
```

rules_engine.py	实时异常规则引擎 (stage 1)
param_correlation.py	事件聚类/前兆/参数排除/复测 (stage 2) + 公共口径 (is_ng/parse_fdate/first_inspection_rows)
process_dimensions.py	工艺维度体检 (P1, 随 stage 2 产出)
drilldown.py	触发检测/观测判定/下钻包/契约 (stage 3, 最大模块)
early_warning.py	EWMA/分级/回放回测/预警报告 (stage 4, P0)
ontology.py	概念/机理/关系单源 (改知识改这里)
knowledge_base.py	决策规则/置信度模型/处置阶梯/diagnose()/规则目录
drilldown_chat.py	规则问答 + LLM grounding + 回退链路
llm.py	六提供商三协议适配器 (纯 urllib)
dashboard.py	affected_model.py over_volume.py 汇总/适配器 (历史命名)

web/ index.html app.js drilldown.js styles.css 原生前端

tests/ 10 个测试文件、190 个用例

docs/ 各功能设计文档 + 本手册

sql/ scripts/ 建表参考 / XLSX 导入工具

十二、测试体系（190 个用例的守护对象）

- **口径守护**：NG 判定、首检/复测、fdate 解析、无符号幅度——错了整个系统跟着错的地方；
- **知识守护**：机理词表完整性、规则绑定、投影行为、置信度算式（数值变了 测试先叫）；
- **确定性守护**：trigger_id/warning_id 跨窗口滑动不变；
- **行为测试**：合成数据验证触发检测、EWMA 报警/不报警/基线冻结/新常态、体检四态、LLM 三协议请求构造与回退（**零外呼**，网络层可注入）。

改任何东西后：`python3 -m unittest discover tests`。测试挂了先看它守护的口径是不是被无意打破。

十三、如何修改与扩展（三层故障定位）

客户接手后遇到"系统说得不对"，先分类再动手：

1. **描述与实际不符**（如明明 3 个 Pad 异常却判"整板同向"）→ 计算逻辑，改 `drilldown.py/early_warning.py` 的判定函数与阈值常量；

2. **根因说法不符合产线经验**（如某机理的签名/动作不对）→ 知识，改 `ontology.py` 机理定义，跑测试，版本串升级；
3. **太松/太紧**（误报多、处置激进）→ 策略，改 `knowledge_base.py` 的先验/乘数/处置阶梯，或 `config` 里的 EWMA 参数——知识与代码都不用动。

常见扩展点：新机种接入（重跑 `early_warning.backtest_grid` 标定 λ/L ）；新增机理（`ontology.py` 加卡 + 守护测试）；新增数据列到位（把对应 evidence 的 availability 从 `not_collected` 改掉，相关机理自动证据点亮）。

十四、已知边界（交付时必须如实告知）

1. **所有阈值/先验标定自单机种单机台 37 天数据**（12 条 NG）。换机种/换线 需重新标定（回测 harness 已具备）；
 2. **13 个机理的工艺内容为领域先验，尚未经产线专家逐条评审**——根因建议在评审完成前应作"参考"使用；
 3. **数据侧缺口**：SPI 判定阈值未接入（margin 非真 Cpk）、PrintDirection/ 擦网时刻/温湿度未采集（对应机理无法自动验证）、fdate 为文本（百万行级 前需真时间戳+索引）；
 4. **LLM 对话是数据出厂行为**：启用后触发上下文（机种/缺陷/参数）发送至 所选大模型服务商，需客户数据治理拍板；不启用则纯离线运行；
 5. **服务无认证**，安全边界依赖网络隔离；
 6. 工艺维度体检当前三卡为"无效应/样本不足/未采集"是**当前数据的如实结论**，不是功能未完成。
-

十五、建议的演示动线（30 分钟版）

1. 打开首页 → 指标区 + 右上角"● 实时"徽标（讲：watcher 在盯表，数据一变全站自动更新）；
2. 实时异常页找带 ☒ 的行 → 进下钻（讲第六节案例：范围/趋势/恢复怎么判、候

- 选怎么排、0.924 怎么算出来的、诊断轨迹逐条展开)；
3. 下钻对话区问"为什么判定为这个范围？"（讲：LLM 优先规则兜底、回答带来源）；
4. 事前预警页（讲：NG 之前的故事——健康矩阵谁在变坏、待确认新常态、接受为新基线的闭环）；
5. 事件与根因页（讲：事件聚类 + 工艺维度体检的"如实四态"）；
6. 机理手册页（讲：知识单源——现场说这张卡不对，改一处全系统跟随）；
7. 收尾讲第十四节边界，给出试点建议（影子模式 2~4 周，攒确认/否决反馈）。
-

术语表

术语	含义
首检/复测	板的第一次检测 / 同板条码更晚时刻的再次检测（不算生产板）
三板连发	同一焊盘连续 ≥ 3 块生产板 NG 且中间无 PASS（严格口径）
三指标	体积/面积/高度偏差幅度（Comp_avdp/aadp/ahdp，无符号）
签名	机理发作时三指标的预期表现模式
先验/把握度	核对证据前/后的根因置信度（ ≥ 0.75 高 / ≥ 0.5 中）
分析契约	analysis_contract，一次触发的唯一权威结论载荷
诊断轨迹	决策四步对一次触发的逐条求值记录（审计链）

EWMA	指数加权移动平均，漂移监控的核心统计量
margin	漂移裕度：距历史 NG 最低观测水位的 3σ 倍数 (非真 Cpk)
新常态	台阶式均值迁移后不回落的水平，需人工"接受 为新基线"
机理	FailureMechanism，根因词表的唯一权威（13 个）